

矿物岩石地球化学通报

Bulletin of Mineralogy, Petrology and Geochemistry

ISSN 1007-2802, CN 52-1102/P

《矿物岩石地球化学通报》网络首发论文

题目: 基于机器学习的水氡异常地震前兆识别
作者: 刘慧, 谷洪彪, 姚玉霞, 鲁明贵
收稿日期: 2025-10-15
网络首发日期: 2026-01-09
引用格式: 刘慧, 谷洪彪, 姚玉霞, 鲁明贵. 基于机器学习的水氡异常地震前兆识别
[J/OL]. 矿物岩石地球化学通报.
<https://link.cnki.net/urlid/52.1102.P.20260109.1056.001>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于机器学习的水氡异常地震前兆识别

刘慧¹, 谷洪彪^{1*}, 姚玉霞², 鲁明贵¹

1. 南京工业大学 交通运输工程学院, 南京 211816; 2. 甘肃省地震局, 兰州 730000

摘要: 水氡是地震流体地球化学前兆监测的关键指标,但其动态演化受构造活动与多种环境因素的耦合影响,因此水氡震前异常信号的有效识别面临显著挑战。本研究基于长短期记忆网络(LSTM)与随机森林(RF)组合的机器学习模型,对甘肃殿沟泉水氡浓度时间序列进行动态建模与预测。在此基础上,以模型预测残差作为异常检测的基础,采用局部离群因子(LOF)算法识别潜在异常信号。为检验水氡前兆信息的可靠性,对同期水温、水位数据进行同种方法的异常识别,以实现多参数异常对应分析。进一步结合同期降水、气温及气压气象观测数据及人为活动资料,排除由非构造因素引起的干扰异常,从而提取出具有潜在构造意义的震前响应信号。研究表明,本文所构建LSTM-RF模型与单一LSTM模型或随机森林(RF)模型相比,表现出更强的稳定性和泛化能力,能有效模拟甘肃陇南地区殿沟泉水的水氡浓度动态演化过程;局部离群因子(LOF)算法可有效识别出水氡及水温、水位与地震事件相关的异常信号。本研究为地震流体地球化学前兆研究提供了新的方法路径与理论依据。

关键词: 机器学习; 水氡浓度; 预测模型; 异常检测; 地震前兆

中图分类号: P65 doi: 10.3724/j.issn.1007-2802.20250133

Identifying seismic precursors from groundwater radon anomalies based on machine learning

LIU Hui¹, GU Hong-biao^{1*}, YAO Yu-xia², LU Ming-gui¹

1. College of Transportation Engineering, Nanjing Tech University, Nanjing 211816, China;

2. Gansu Earthquake Agency, Lanzhou 730000, China

Abstract: Radon in groundwater is a critical indicator for monitoring seismic fluid geochemical precursors. However, the effective identification of pre-seismic anomalous signals faces significant challenges, as the dynamic evolution of radon is co-influenced by the coupled effects of tectonic activities and various environmental factors. In this study, based on the hybrid machine learning model of the Long Short-Term Memory (LSTM) and Random Forest (RF) networks, we have conducted dynamic modeling and prediction for the variation of radon concentration in groundwaters of the Diangou Spring in Gansu Province with the time. Subsequently, by employing the model's prediction residuals as the basis of anomaly detection, the Local Outlier Factor (LOF) algorithm is adopted to identify potential anomalous signals caused by the earthquake. To verify the reliability of the precursor information of radon concentration in groundwater, the same method is used to identify anomalies in data of groundwater temperatures and groundwater levels of the same period to achieve the multi-parameter anomaly correspondence analysis. Furthermore, by incorporating concurrent meteorological data (meteoric water, air temperature, and barometric pressure) and records of anthropogenic activities, the interference anomalies caused by non-tectonic factors are excluded, thereby the pre-earthquake response signals with potential tectonic significances are extracted. The research results demonstrate that the proposed LSTM-RF

收稿编号: 2025-0221, 2025-10-15 收到, 2025-12-09 改回

基金项目: 国家自然科学基金资助项目(42372282); 地震预测预警业务专项课题(ZX2505004)

第一作者简介: 刘慧(2001—), 女, 硕士研究生, 研究方向: 人工智能与防震减灾. email: 1592663326@qq.com

*通信作者简介: 谷洪彪(1984—), 男, 博士, 教授, 研究方向: 人工智能与防震减灾. email: hongbiaosw@126.com

引用此文:

刘慧, 谷洪彪, 姚玉霞, 鲁明贵. 2025. 基于机器学习的水氡异常地震前兆识别. 矿物岩石地球化学通报, doi: 10.3724/j.issn.1007-2802.20250133

Liu H, Gu H B, Yao Y X, Lu M G. 2025. Identifying seismic precursors from groundwater radon anomalies based on machine learning. Bulletin of Mineralogy, Petrology and Geochemistry, doi: 10.3724/j.issn.1007-2802.20250133

hybrid model has superior stability and generalization capability compared to the standalone LSTM or RF models. It can be used to effectively simulate the dynamic evolution of radon concentrations in groundwaters of the Diangou Spring in the Longnan region of Gansu Province. The LOF algorithm can be used to effectively identify anomaly information of radon concentrations, temperatures and levels of groundwaters associated with seismic events. It provides a novel methodological pathway and theoretical basis for the research of seismic fluid geochemical precursors.

Key words: machine learning; radon concentration in groundwater; prediction model; anomaly detection; seismic precursor

0 引言

水氢作为地下流体中重要的地球化学组分, 其在地震孕育与发生过程中可能出现的灵敏变化, 长期以来被视为有效的地震流体前兆观测指标(Singh et al., 1991; Yasuoka et al., 2005; Hartmann and Levy, 2005; Hashemi et al., 2013; Zhang et al., 2020; 李营等, 2022)。然而, 地下流体动态受到复杂的构造-水文-气象耦合影响。水氢浓度的时序变化既受到构造应力变化的影响, 也受到降水、气压及气温等环境因素的非构造影响(Paudel et al., 2018)。因此, 水氢浓度时间序列变化是一个典型的非线性、非平稳信号。如何从复杂的背景噪声中有效提取出可靠的震前异常信息, 是水氢地震前兆研究的关键。

近年来, 随着人工智能技术的飞速发展, 机器学习与深度学习模型逐渐成为时间序列预测与异常检测研究的先进工具。长短期记忆网络、随机森林等算法因其强大的非线性拟合与时序建模能力, 已被广泛应用于地下水动态预测及异常信息挖掘(袁爱璟等, 2021; 王锦红和蒋海昆, 2023)。人工神经网络因其长期依赖关系学习能力, 且擅长通过其门控机制捕获时间依赖关系, 在预测领域取得了一定的成效(Kulahci et al., 2009; Sreekanth et al., 2009; 王宇等, 2015)。而长短期记忆网络(LSTM)作为一种特殊的循环神经网络, 同样能够有效模拟和预测地下流体的动态变化, 有助于识别水文异常、探测地震前兆(Yan et al., 2021)。然而, 人工神经网络其固有的黑箱特性导致模型解释性弱, 难以量化不同特征对结果的贡献(Zhang et al., 2021)。随机森林(RF)算法不同于人工神经网络, 其在分类和回归任务中表现出更好的准确性和鲁棒性, 且对复杂系统具有更强的拟合能力(Tyralis et al., 2019; Gu et al., 2022); 但随机森林作为集成学习算法, 本身缺乏对数据中时间顺序依赖关系的建模能力。因此, 长短期记忆网络与随机森林可尝试结合, 以构建出兼具时序动态建模能力与高精度特征重要性解释的组合模型, 从而进一步提升对地下流体中前兆信息的识别精度与可解释性。然而, 如何有效融合

LSTM与随机森林的优势, 相关研究还较为缺乏。

在地震前兆数据的异常信息挖掘研究中, 传统异常检测基于统计方法且依赖于设定经验阈值, 灵活性差且易漏检(赵栋等, 2013; 鲁明贵等, 2024); 而在机器学习方法中, 局部离群因子(LOF)算法因其独特的局部密度评估机制, 展现出一定的优势(杨德贺等, 2017; 朱瑞杰等, 2023)。另一方面, 现有地震前兆研究多聚焦于单一参数, 对多源数据融合探索有限(孙小龙等, 2018; 鲁明贵等, 2024)。特别是在水氢异常识别中, 如何有效排除气象干扰、提升异常信息的可靠性, 仍是当前研究中尚未解决的关键问题。

针对上述问题, 本研究以甘肃陇南地区殿沟泉的水氢观测数据为核心, 构建一种基于LSTM-RF的组合预测模型, 将深度学习(即长短期记忆网络)的时序动态捕捉能力与集成学习(即随机森林)的高精度拟合及可解释性优势相结合, 模拟水氢浓度的动态演变过程。基于局部离群因子算法对水氢浓度观测数据进行异常识别, 并结合水温、水位及气象观测资料, 进行多参数异常检测对比及分析。旨在通过交叉验证与气象因素干扰排除, 提升水氢异常地震前兆识别的可靠性与准确性。本文通过方法创新与多源数据融合, 为识别地下流体前兆异常信号提供了新思路, 为水氢地震前兆的识别与研究提供新的技术路径与实证支持。

1 研究区概况

研究区为甘肃陇南地区, 选取的地下流体观测点为甘肃武都殿沟流体观测站的殿沟泉与两水地震台观测井(图1)。研究区年平均气温14.7℃, 年降雨量400 mm左右, 属亚热带半湿润气候。该地处在南北地震带中段的天水—武都—文县地震带。在地形上沿天水—武都—文县一带正是东西秦岭间具有显著变化的地段。东侧均为1500m以下的山地, 两侧多为2000m以上的群山, 形成极为明显的阶梯状地形。该地对监测甘东南及陕、甘、川三省邻近地区的地震起着重要作用, 是甘肃省地震活动重点监测的地区之一。

本研究水氢数据来源于殿沟泉观测, 该泉出露于北东向的断层破碎带上, 断层北盘为上志留系的厚层




图1 研究区地形构造背景图(使用arcmap软件创造)

Fig.1 Topographic and tectonic setting map of the study area (Create using the arcmap software)

状灰岩。南盘为板岩和千枚岩,在该处形成高约20m的跌水,在陡岩的沟侧,泉水从灰岩裂隙中涌出,属上升泉。该泉流量为0.700~1.400 L/s,水温为 17.6 ± 0.5 °C。经过多年观测资料证实,殿沟泉作为地震水文地球化学观测点是较为理想的,其曾多次记录到地震前兆信息(刘春国等,2021)。

2 数据来源与研究方法

2.1 数据来源

本研究的水氢数据及气象三要素(降水、气温、气压)数据,均为甘肃武都殿沟流体观测站中殿沟泉的观测数据。为更直观解释水氢变化的机理,研究数据还包含了殿沟泉的泉水流量数据与泉水水温数据。其中,水氢浓度观测仪器为FD-125测氢仪,数据精度为日值;气象数据观测仪器为RTP-II三要素仪,精度均为小时值;泉水流量数据与水温数据精度为日值。为进行水氢与气象动态趋势对比分析,采用累积法将降水数据转化为日值,气温、气压数据则采用算术平均法数

据处理为日值。水温、水位观测数据来源于两水地震台观测井,距殿沟泉约11.3 km。水温、水位数据观测仪器分别为ZKGD3000-NL水位仪、SZW-2数字式温度计,精度均为小时值。上述数据资料连续,且质量高,基本信息如表1所示。

近年来,发生在甘肃武都殿沟泉周边地区5级以上的地震共有三次(图1),分别为2022年6月10日四川马尔康 $M_S 6.0$ 地震、2023年12月18日甘肃积石山 $M_S 6.2$ 地震以及2025年9月27日甘肃陇西 $M_S 5.6$ 地震,具体地震信息详见表2。上述地震的震级及与殿沟泉、两水观测井的震中距关系均符合震级与震中距的经验关系(Elmaghraby and Lotfy 2009):

$$M = 1.93 \log_{10} 3.58D \quad (1)$$

其中, M 为震级, D 为震中距。

殿沟泉水氢及两水观测井水温、水位数据中很可能记录到上述地震的前兆信息。因此,选取四川马尔康 $M_S 6.0$ 地震、甘肃积石山 $M_S 6.2$ 地震以及甘肃陇西 M_S

表 1 水氡浓度与流体其他观测要素信息表

Table 1 Comprehensive information table on groundwater radon concentration and other fluid observation parameters

数据类别	数据来源	时间跨度	精度	数据处理方法	研究内容
水氡浓度	殿沟泉	2014.1.1至2025.9.30	日值	—	时间序列预测与异常检测
水温	两水观测井	2022.1.1至2025.9.30	小时值	—	异常检测
水位	两水观测井	2022.1.1至2025.9.30	小时值	—	异常检测
降水	殿沟泉	2022.1.1至2025.9.30	小时值	累积法转化为日值	与异常点序列分布对比分析
气温	殿沟泉	2022.1.1至2025.9.30	小时值	算术平均法转化为日值	与异常点序列分布对比分析
气压	殿沟泉	2022.1.1至2025.9.30	小时值	算术平均法转化为日值	与异常点序列分布对比分析
泉水流量	殿沟泉	2022.1.1至2025.9.30	日值	—	与水氡序列分布对比分析
泉水水温	殿沟泉	2022.1.1至2025.9.30	日值	—	与水氡序列分布对比分析

注：“—”表示该参数精度未经转化处理。

表 2 2022—2025年研究区 $M_S>5.0$ 地震要素信息表

Table 2 Table of seismic parameters ($M_S>5.0$) in the study area (2022—2025)

参考位置	发震时刻	震中位置		M_S	震中距/km
		$\lambda_E/(^{\circ})$	$\varphi_N/(^{\circ})$		
四川阿坝州马尔康市	2022/6/10 1:28:34	101.82	32.25	6.0	317
甘肃临夏州积石山县	2023/12/18 23:59:30	102.79	35.7	6.2	323
甘肃定西市陇西县	2025/9/27 5:49:57	104.58	34.91	5.6	172

5.6地震作为研究背景,对水氡及水温、水位进行异常检测,以提取出与上述三次地震相关的、具有潜在构造意义的震前响应信号。

2.2 时间序列预测模型

2.2.1 长短期记忆网络(LSTM) 长短期记忆网络(Long Short-Term Memory,LSTM)是一种特殊的循环神经网络(RNN)架构,旨在解决传统RNN在处理长序列时存在的梯度消失或爆炸问题。LSTM通过门机制(输入门、遗忘门、输出门)和细胞状态对时间序列数据中的趋势和季节性信息进行建模,能够有效捕获长时间依赖关系。LSTM模型主要计算过程如下。

(1)遗忘门(f_t)决定从先前细胞状态中丢弃信息的比例。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2)$$

(2)输入门(i_t)控制新信息的流入。

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (3)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (4)$$

(3)输出门(o_t)决定向下一个神经元传递的信息。

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (6)$$

(4)细胞状态(C_t)更新,并作为长时记忆向后传递。

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (7)$$

在上述公式中, x_t 是模型接收的 t 时刻的输入; b_f 与 W_f 分别是遗忘门对应的偏置与权重矩阵; b_i 与 W_i 分别是输入门对应的偏置与权重矩阵; b_c 与 W_c 分别是当前细胞状态的更新向量 C_t 对应的偏置与权重矩阵; b_o 与 W_o 分别是输出门对应的偏置与权重矩阵; h_t 与 h_{t-1} 是当前时刻与上一时刻的隐藏层状态。

2.2.2 随机森林(RF) 随机森林(Random Forest, RF)是一种基于决策树的集成学习方法。该方法通过构造多棵决策树,并综合其预测结果(分类任务采用投票,回归任务采用平均)输出,具有较强的抗过拟合能力。随机森林能够有效捕捉时间序列中的非线性关系和特征交互效应,同时对异常值具有较好的鲁棒性。其最终水氡预测值为多棵树的平均:

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N T_i(x) \quad (8)$$

式中, $T_i(x)$ 为第 i 棵树对输入 x 的预测值, N 为树的总数。

2.2.3 LSTM-RF组合模型 LSTM-RF组合模型通过长短期记忆网络(LSTM)捕捉时间序列的长期依赖特征,继而利用随机森林(Random Forest)对提取的深层特征进行非线性回归预测。模型将LSTM作为特征提取器,并将提取的水氡时序特征输入随机森林模型,

随机森林通过多决策树集成学习对非线性关系拟合。该组合发挥出LSTM在时序特征学习和随机森林在非线形回归方面的互补优势,通过级联特征提取与回归机制,有效提升水氡时间序列预测的准确性和泛化能力。混合模型具体的实现步骤如下。

(1)使用LSTM处理原始水氡时间序列数据,得到水氡时间序列的隐藏状态 h_t 或者预测值 y_t^{LSTM} 。

(2)将 h_t 或 y_t^{LSTM} 输入随机森林模型,预测最终的输出 y_t^{final} 。

(3)通过联合优化提升模型性能。

$$\begin{aligned} h_t &= \text{LSTM}(x_t) \\ y_t^{\text{final}} &= \text{RF}(h_t) \end{aligned} \quad (9)$$

2.2.4 模型评价指标 在时间序列预测模型的性能评估中,通常采用以下四个核心指标进行综合衡量:

均方根误差(Root Mean Square Error, RMSE),是预测值与实际观测值之间差异的平方的均值的平方根,其表达式为:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (10)$$

式中, n 为样本数量, y_i 为第 i 个实际观测值, $\hat{y}_i$ 为对应的预测值。该指标能够直观反映预测的绝对精度。

平均绝对误差(Mean Absolute Error, MAE),计算的是预测误差绝对值的平均值。该指标能更稳健地反映预测误差的总体水平,其表达式为:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (11)$$

平均绝对百分比误差(Mean Absolute Percentage Error, MAPE),以百分比形式衡量相对误差。该指标具有无量纲特性,便于在不同尺度的数据集或模型间进行比较,是评估预测相对精度的常用标准,公式为:

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (12)$$

决定系数(coefficient of determination, R^2),表征模型对目标变量方差的解释能力,定义为:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (13)$$

式中, $\bar{y}$ 为目标变量的均值。 R^2 的取值范围在0~1之间,其值越接近1,表明模型的拟合优度越高,对数据变异的解释能力越强。

2.3 局部离群因子(LOF)算法异常检测

局部离群因子(Local Outlier Factor, LOF)算法是

一种基于相对密度的异常检测方法(Alghushairy et al., 2021),该方法通过量化数据对象与其局部邻域密度之间的偏离程度来识别异常点。其算法步骤如下:

(1)计算 k -距离(k -distance)。对于每个数据点 p ,定义其 k -距离为到 p 的第 k 个最近邻居的距离,记作 $d_k(p)$ 。这表示至少有 k 个点位于 p 周的距离不大于 $d_k(p)$ 。

(2)计算可达距离(reachability distance)。对于数据点 p 和 o , p 对 o 的可达距离定义为:

$$\text{reachdist}_k(p, o) = \max\{d_k(o), d(p, o)\} \quad (14)$$

其中, $d(p, o)$ 是点 p 和点 o 之间的实际距离。

(3)计算局部可达密度(Local Reachability Density, LRD)。对于每个数据点 p ,其局部可达密度(LRD)定义为:

$$\text{LRD}_k(p) = \left[\frac{\sum_{o \in N_k(p)} \text{reachdist}_k(p, o)}{|N_k(p)|} \right]^{-1} \quad (15)$$

式中, $N_k(p)$ 是 p 的 k -最近邻集合,包括 p 自身。

(4)计算局部离群因子(Local Outlier Factor, LOF)。对于每个数据点 p ,其局部离群因子(LOF)定义为:

$$\text{LOF}_k(p) = \frac{\sum_{o \in N_k(p)} \frac{\text{LRD}_k(o)}{\text{LRD}_k(p)}}{|N_k(p)|} \quad (16)$$

当 $\text{LOF}_k(p)$ 接近1时,表示 p 类似于其邻居;大于1时, p 在局部区域内可能是异常点;小于1时, p 更可能是密集区域内的一个正常点。

本研究基于局部离群因子(LOF)对水氡及水温、水位进行异常识别,该方法契合地下流体“局部突变即为异常”的特征。与传统基于固定阈值或统计分布的方法相比,LOF算法能自适应地捕捉数据中复杂的非线性关系;与其他机器学习方法(如隔离森林的“全局隔离”或One-Class SVM的“全局边界”)相比,LOF算法独特的“局部密度比较”机制能捕捉到数据中的微小局部密度变化,即能有效识别出在全局看似正常、却在局部时间范围内表现异常的点。因此,该方法在识别地震前兆这类局部性、相对性的微弱异常信号方面具有突出的优势。

3 结果与讨论

3.1 水氡时间序列预测结果

为构建水氡浓度的时间序列预测模型,本研究将2014年1月1日至2021年12月31日设定为模型训练期,利用该时段的历史数据进行模型拟合与参数训练,对2022年1月1日至2025年9月30日的水氡浓度进行预

测。模型训练集与测试集划分如图2所示,测试集数据较训练集数据稳定性有所提升。进一步将单一随机森林模型、LSTM模型以及LSTM-RF混合模型的预测序列与真实观测值进行了可视化对比,直观展现各模型在预测精度、趋势捕捉及滞后性等方面的表现,以综合评估模型的预测性能。为公平比较各模型性能,本研究对关键参数进行统一设置,单一模型与混合模型的关键参数设置如表3所示。

采用随机森林模型对水氡浓度数据进行时间序列预测,结果如图3及表4所示。该模型能有效地捕捉数据的整体季节性、周期性规律,对历史观测中重复出现的年变特征具有较强的学习和再现能力。且相比于复杂的时间序列模型,随机森林训练速度更快、参数调优更简单、对异常值不敏感。这些特点使得该模型能够在保证基本季节性、周期性、准确性的基础上,保持

较好的泛化能力。

然而,随机森林在时序预测中只能基于静态特征(如月份、季节等)进行提取与学习,而无法真正学习时间序列的动态演变规律和长期依赖关系,导致模型缺乏对序列趋势变化和异常波动的捕捉能力。且在测试集上负的 R^2 值和增大的误差,表明其缺乏时序理解能力、对数据分布变化敏感,并存在过拟合。因此,随机森林模型的预测效果主要表现为对水氡数据季节性模式的简单复制,预测值呈现出明显的“年变效应”,即后一年的预测曲线基本重复前一年的变化形态。

而采用LSTM模型进行水氡时间序列预测时,相较于随机森林模型,其能够更好的学习水氡数据的整体变化趋势,在短期预测中的表现相对更稳定(图4)。该模型能够自动学习数据中的周期性、趋势性和季节性特征,无需人为地进行特征工程。其记忆单元的状态




图2 水氡浓度时间序列训练集与测试集划分示意图

Fig.2 Schematic of the training and test set partitioning for groundwater radon concentration time series

表3 模型关键参数配置

Table 3 The configuration of key parameters for the models

关键参数	LSTM模型	RF模型	LSTM-RF混合模型
神经网络结构	1层LSTM+2层全连接	—	1层LSTM+1层全连接
隐藏层层数	1层LSTM隐藏层	—	1层LSTM隐藏层
每层神经元数	输入→120→60→30→1	—	输入→120→30→1
训练窗长	60天	—	60天
训练步长	1天	—	1天
决策树数量	—	100棵决策树	100棵决策树
决策树最大深度	—	最大分裂100次	最大分裂100次
随机丢弃率	30%	—	30%
最小叶节点	—	5个样本	5个样本
分裂准则	—	均方误差(MSE)	均方误差(MSE)
优化器	Adam	—	Adam

注:“—”表示该参数在该模型中无意义或不相关。




图3 随机森林模型预测水氡浓度结果图(a)与预测残差图(b)

Fig.3 Prediction results (a) and residuals (b) of radon concentrations in groundwaters using the Random Forest model

表 4 随机森林模型性能指标

Table 4 Performance metrics of the Random Forest model

指标	训练集	测试集	差值
RMSE	65.12 Bq/L	95.60 Bq/L	30.48 Bq/L
MAE	51.92 Bq/L	76.37 Bq/L	24.45 Bq/L
MAPE	3.71%	5.08%	1.37%
R^2	0.7291	-2.3844	3.1135

态持续更新机制使得模型能够捕捉到水氡浓度数据中跨越数十天甚至是更长时间尺度的依赖关系。

但随着预测时间延长,LSTM模型的预测精度会逐渐下降,出现明显的平滑化和滞后效应,这是该模型在处理长期依赖和突变检测方面的固有的局限性。LSTM模型性能指标如表5所示,该模型在训练集上表现出色($R^2=0.9939$,MAPE=0.51%),但在独立测试集




图4 LSTM模型预测水氡浓度结果图(a)与预测残差图(b)

Fig. 4 Prediction results (a) and residuals (b) of radon concentrations in groundwaters using the LSTM model

表 5 LSTM模型性能指标

Table 5 Performance metrics of the LSTM model

指标	训练集	测试集	差值
RMSE	9.54 Bq/L	32.26 Bq/L	22.72 Bq/L
MAE	7.33 Bq/L	18.62 Bq/L	11.29 Bq/L
MAPE	0.51%	1.26%	0.75%
R^2	0.9939	0.5795	0.4144

上性能下降($R^2=0.5795$, $MAPE=1.26\%$)。由于采用自回归的滚动预测方式,前一步的预测误差会不断累积到后续预测中,导致误差越来越大,长期预测性能逐渐衰减;同时该模型倾向于学习水氢数据的整体模式而难以捕捉到数据中突发性的变化。因此,当地震等异常事件引起水氢浓度突变时,模型的响应会明显滞后,预测曲线会呈现出过度平滑的特征。

基于LSTM-RF混合模型对水氢浓度观测数据进行时间序列预测,结果如图5所示,该模型表现出较优秀的预测性能。该混合模型借助LSTM提取时间序列的深层时序特征的优势,再通过随机森林对LSTM的初步水氢序列的预测结果进行校正和优化,有效地提升了组合模型对水氢数据预测的稳定性和准确性。在预测效果上,组合模型能够更好地捕捉水氢数据的非线性变化模式,减少了数据对突发性事件(如地震)的响应滞后;同时借助随机森林特征重要性分析,预测结果能够更好的被清楚解释。该模型结合了时序建模能力与集成学习优势,在保持对长期趋势学习能力的同时,显著降低了预测结果的波动性和不确定

性,体现出深度学习与传统机器学习方法组合的显著优势。

基于评估指标对组合预测模型进行定量分析(表6),其中决定系数约为0.8,表明能够解释大部分数据变异;预测平均绝对百分比误差仅为1.18%,表明预测值与实际值的平均偏差较小,约17.62 Bq/L的绝对误差。且测试集预测指标普遍优于测试集,主要源于测试期(2022年至2025年)数据稳定性提升,模型在更稳定的测试数据上发挥出更优的预测潜力。从时间维度的角度分析,2023年和2025年的预测误差相对较低(RMSE约为21),而2022年误差稍高(RMSE约为27),该年份可能受到地震活动等外部因素影响。总体而言,LSTM-RF组合模型可有效捕捉氢浓度的时序规律。

3.2 多参数异常检测结果对比

LSTM-RF组合模型能够有效捕捉数据中的主要规律和趋势,因此其预测值与实际值之间的差异(即残差)应表现为随机、无关的白噪声(Box et al.,2015)。

表 6 LSTM-RF混合模型性能指标

Table 6 Performance metrics of the LSTM-RF hybrid model

指标	训练集	测试集	差值
RMSE	29.38 Bq/L	20.34 Bq/L	9.04 Bq/L
MAE	22.54 Bq/L	17.62 Bq/L	4.92 Bq/L
MAPE	1.58%	1.18%	0.40%
R^2	0.9458	0.8467	0.0991




图5 LSTM-RF混合模型预测水氢浓度结果图(a)与预测残差图(b)

Fig.5 Prediction results (a) and residuals (b) of radon concentrations in groundwaters using the LSTM-RF hybrid model

若残差序列中出现显著的、非随机极端值,则表明存在该模型未捕捉到的异常事件发生(如突发故障、特殊事件干扰)。且对残差进行异常识别,可以将复杂的原始水氡序列异常检测转化为更简单、清晰的残差序列的异常检测,以提高对微小异常信息的识别灵敏度与解释性。如Audibert等(2020)提出的USAD模型,其通过对抗性训练的自编码器来放大异常数据点的重构误差(即残差),从而实现高效的无监督异常检测。

因此,本研究基于LOF算法对水氡预测残差与观测数据(即真实值)进行异常检测并将结果进行对比,尝试识别潜在的异常点。首先,对原数据进行标准化处理:数据清洗(填补缺失值)、去趋势(移除长期变化)、去季节性(消除周期性波动)、标准化(转换为均值为0、标准差为1的标准正态分布)。该处理可消除原始数据的量纲差异和系统性变化,使不同来源、不同尺度的数据具有可比性,为异常检测算法提供标准化输入。而对于LOF算法的关键参数 k 值,采用基于数据特征的动态调整策略确定,以定义计算每个数据点的局部密度时考虑的最近邻数量。首先,基于密度估计算法,以样本数量的平方根作为基准参考值。其次,结合数据特性设置百分比约束,确保 k 值介于数据总量的1%~10%之间,避免因数据稀疏或密集导致误判。再者,设定绝对边界值,为不同规模数据集提供适应性调整。如水氡预测残差数据采用较小 k 值范围(5~25)以增强对细微异常的敏感性;原始数据采用较大 k 值范围

(20~60)以捕捉宏观异常模式。并采用分位数法,将LOF得分分布的98.7%分位数设定为异常判定的临界值,以自适应地识别局部密度显著偏低的离群点。

如图6、图7所示,水氡浓度预测残差与观测数据异常点主要集中于三次地震事件发生前后的90天内和每年7月至9月,且水氡观测数据异常点较预测残差异常点分布更集中。

为进一步评估LOF算法识别出的水氡异常信息的可靠性,本研究对同期水温与水位观测序列进行异常检测,并将其结果与水氡异常检测结果进行对比分析。通过上述方式以实现多参数交叉验证,捕捉在不同参量中可能相互印证的异常前兆信号,从而增强异常识别的说服力。

本研究选取了两水站观测井在2022年1月1日至2025年9月30日的水温、水位观测数据,经与前文一致的标准化处理后,进行并行的LOF异常检测。参数 k 值采用中等范围(10~30)以平衡检测灵敏度与稳定性,检测结果详见图8。水温、水位数据的异常点同样主要集中于三次地震发生前后的90天内和每年7月至9月,与水氡浓度、水氡预测残差异常点在时间序列分布上具有较好的一致性。而每年7月至9月为甘肃陇南地区的雨季,年降雨量400 mm左右,对水氡观测影响较大,因此很可能存在降水等气象因素或其他非构造因素引起的干扰异常,需要进一步对异常点进行分析与讨论,以获取真实具有构造指示意义的异常信息。




图6 水氡预测残差的LOF异常检测结果图(a)与异常得分图(b)

Fig.6 Results (a) and anomaly scores (b) for prediction residuals of radon concentrations in groundwaters by using the LOF anomaly detection




图7 水氡观测数据的LOF异常检测结果图(a)与异常得分图(b)

Fig.7 Results (a) and anomaly scores (b) for observation data of radon concentrations in groundwaters by using the LOF anomaly detection




图8 水温数据(a)与水位数据(b)的LOF异常检测结果

Fig.8 Results of the LOF anomaly detection for data of groundwater temperature (a) and groundwater level (b)


3.3 讨论

基于LOF算法对2022年1月至2025年9月的水氡预测残差、水氡观测值与水温、水位数据进行异常检验,结果统计为图9。水氡预测残差异常点(图9b)与其他参数的异常点在时间序列分布上具有较好的一致性。图中,7条多参数异常重合线指示的七组异常点在时间序列分布上基本重合,即水氡、水温及水位三种参量可相互验证,提升水氡预测残差异常信息的可靠性。

但在地震地球化学观测中,水氡浓度受多种非构造

因素影响,其中气象条件与人为活动是两类主要干扰源。气象方面,降水通过加载与稀释作用影响水氡浓度;气压波动通过抽吸或压缩效应调控氡的运移;温度变化则制约其溶解度及流体活动性。人为方面,仪器状态变异、周边工程活动等,通过改变水文条件或引入误差而改变观测数据。因此,为有效区分非构造因素干扰与潜在构造应力响应,还需对7组异常点进一步做讨论分析。

3.3.1 非构造因素 为系统性地排除由气象条件引起的“假异常”,本研究对水氡数据与气象三要素(降



(a)水氢异常得分图;(b)残差异常得分图;(c)水位异常得分图;(d)水温异常得分图。图中7条垂直虚线为多参数异常重合线

图9 多参数异常得分时间序列图

Fig.9 The variation of multi-parameter anomaly scores with time

水、气压、气温)进行标准化处理后进行对比,结果如图10所示。图中橙色标记指示了基于LOF算法识别出的七组时间序列基本重合的异常点,共计30个。表7中系统列出了这些异常点的集群时段、水氢变化特征等,并结合同期降水、气温及气压气象观测数据及人为活动资料讨论水氢预测残差的异常点成因。


以往的研究表明,泉水流量和水温同样对水氢的影响显著,且更能直观解释水氢变化的机理(Liu et al., 2025)。在正常水文状态下,降雨后流量增大与水氢浓度降低同步发生,可直观印证降雨稀释机理;而水温周期性升高与水氢浓度的负相关响应,则直接体现出温度升高导致水中氢气脱逸增强的物理化学过程。图11同步展示了水氢浓度、泉流量及水温三者随时间的变化趋势,便于对比分析以进一步探讨水氢变化的机理。

在异常检测期内,人为活动对水氢的影响相对较小,未产生相应的“异常现象”;而水氢时间序列曲线与气象参数之间存在一定的关联性。如在雨季强降水事件发生后,泉水流量上升,水氢浓度常呈现滞后性下降,随后逐渐恢复至原有水平(图10a)。水氢与气温在整体变化趋势上具有一定同步性,如2023年1月至

2024年4月期间,两者标准化数值基本吻合;然而在2022年1月至5月、2024年7月至9月及2025年6月至8月时段中,水氢与气温曲线出现明显偏离(图10b)。其中2024年7月至9月、2025年6月至8月时段,降雨量显著增大,泉水流量升高,故上述时段的偏离与雨季降水有关;2022年1月至5月段的偏离则无明显相关气象变化,且水温大幅度降低,很可能为潜在构造应力响应。水氢与气压之间整体上表现为相反的变化趋势,但在上述相同时段内,该相关性也有所减弱(图10c)。

3.3.2 潜在构造应力响应 通过整合同期降水、气温、气压气象观测数据与泉水流量、水温观测数据,以及人为活动记录,大部分水氢异常点可被合理解释。但仍存在若干突出异常事件——如第1组(2022年4月27日至5月7日)、第4组(2023年7月26日至7月29日)与第5组(2023年10月11日至11月5日)的高值异常——无法完全归因于已知气象因素或人为干扰,且同期流量、水温也表现出复杂的协同变化模式。

其中,第1组的异常指示了2022年1月至5月段水氢与气温、气压标准化数值显著偏离现象,水氢数据与水温数据均表现出破年变特征,即氢浓度显著偏离其长期背景波动范围与季节性变化规律,较往年同期数



(a)水氡与降水标准化图;(b)水氡与气温标准化图;(c)水氡与气压标准化图

图10 水氡与气象三要素标准化对比

Fig.10 Comparison of standardized groundwater radon and three meteorological parameter data

表 7 7组不同观测要素重合异常时段及水氡异常成因

Table 7 Coincident anomalous periods of multiple observational elements and causes of groundwater radon anomalies

组别	异常参数	最高异常得分	异常时段	异常点数量	水氡变化特征	水氡异常成因
1	水氡预测残差、水温、水位	7.26	2022.4.27—5.7	3	破年变高值异常,较往年偏高近150 Bq/L	温度回升与潜在构造活动
2	水氡观测值、水氡预测残差、水温、水位	53.49	2022.7.4—7.21	13	低值异常,下降最大幅度230 Bq/L	雨季降雨稀释(日降雨量最高约为41 mm)
3	水氡观测值、水氡预测残差、水温	6.08	2022.8.18—9.1	4		
4	水氡观测值、水氡预测残差、水温、水位	13.08	2023.7.26—7.29	5	高值突跳-快速下降异常,幅度70 Bq/L	夏季高温(28 ℃)、强降雨稀释(累计降雨量约42.3 mm)与潜在构造活动耦合作用
5	水氡预测残差、水温、水位	5.34	2023.10.11—11.5	4	高值异常,上升幅度70 Bq/L	潜在构造活动
6	水氡观测值、水氡预测残差、水温、水位	21.28	2024.7.17—7.25	6	低值异常,最大幅度160 Bq/L	雨季降雨稀释(日降雨量最高约为56 mm)
7	水氡观测值、水氡预测残差、水温、水位	7.93	2025.6.24—7.6	5	低值异常,幅度80 Bq/L	强降雨稀释(累计降雨量约为57.5 mm)

据偏高近150 Bq/L, 而水温较往年偏低;第4组异常时段内,水氡数据出现高值突跳、快速下降的现象,而流量与水温则表现出同步升降;第5组异常时段内,水氡数据打破原有的平稳变化,出现速度较快、较大幅度的浓度升高,而水温持平。这种与“常理”不符的现象,指示异常可能源于深部构造活动,而非浅部环境干扰。且上述异常出现后5个月内,均有地震事件被记录(四川马尔康 M_S 6.0地震、甘肃积石山 M_S 6.2地震),表现出

较强的时序关联性。

然而,3组水氡异常(第1、4、5组)在形态特征上存在明显差异。第1组异常(对应马尔康 M_S 6.0地震)表现为“破年变”型的高值趋势性变化;而第4、5组异常(对应积石山 M_S 6.2地震)则表现为“高值突跳-快速下降”或“快速上升”的突变形态。考虑到两次地震的震级和震中距(约320 km)接近,异常形态的差异可能并非主要源于地震参数的不同,而更可能反映了孕震过




图11 水氡浓度、流量及水温时序对比图

Fig.11 Comparative time-series plot of groundwater radon concentration, discharge, and groundwater temperature

程不同阶段和不同发震断层运动性质(震源机制)的前兆响应特征。

从孕震阶段分析,曾文浩等(2015)对甘东南地区2013年岷县漳县 $M_s6.6$ 地震的研究表明,该区域地震前兆异常具有清晰的阶段性,即存在反映区域应力持续积累的中短期异常和临近破裂前的典型短临异常。因此,本研究中持续时间较长的“破年变”异常可能属于中短期异常范畴,反应出孕震中期较大范围的应力场调整;而“高值突跳”则属短临异常特征,可能对应震源区临近破裂时裂隙的快速变化或深部流体的急剧运移。

从区域构造动力背景看,两次地震均发生在由青藏高原向北东方向推挤所产生的区域构造应力场中(汤大委,2023)。然而,不同的构造部位和断层性质导致了差异化的局部应力-应变过程。对2022年马尔康 $M_s6.0$ 地震的研究表明,其发震断层(松岗断裂附近)以走滑剪切性质为主,应力积累和调整过程可能更具持续性(汤大委,2023)。这种稳定的应力加载,更可能在观测点形成反映大范围、趋势性扩容的“破年变”型异常。相比之下,2023年积石山 $M_s6.2$ 地震发生在拉脊山断裂带上,该区域位于多个块体的交汇部位,

应力环境更为复杂(汤大委,2023)。初步研究表明,其破裂机制包含显著的逆冲分量(Guo et al.,2025),这类断层活动需要积累更高的应力以克服正压力,其临震前的失稳过程可能更急剧,从而更容易触发沿构造通道发生的、反映流体脉冲式释放的“高值突跳”型异常(张慧等,2005)。

因此,综合分析认为,第1组、第4组与第5组共计12个异常点,在排除气象与人为干扰因素影响后,其时空演化特征与构造活动密切相关。这些异常不仅与两次地震事件在时间上存在对应关系,更在形态上分别体现了走滑型地震的中期趋势性响应和逆冲型地震的短期突变性响应。因此,这些异常极有可能反映了不同震源机制地震在孕震末期至临震阶段的应力调整与流体运移过程,是具有构造物理意义的震前异常信号。

4 结论

(1)LSTM-RF组合模型在水氡时序预测方面具有更强的稳定性和泛化能力;基于该模型的预测残差异常检测与多参数协同验证方法,能有效识别并增强异常信号的可信度,为从复杂背景中提取前兆信息提供

了新思路。

(2) LOF异常检测方法能够有效识别出四组数据(水氡观测值、水氡预测残差、水温、水位)序列中潜在的异常点。该方法相较于设定固定阈值的传统方法,能更好地适应水氡等地下流体数据的波动特性,成功识别出水氡数据中12个具有前兆指示意义的震前短临异常点。

(3)在对殿沟泉水氡数据异常点的异常成因讨论中,结合区域构造应力场与震源机制分析,排除了环境因素与人为活动干扰的可能。因此,这些异常点很可能是具有构造指示意义的异常信息,表明殿沟泉水氡记录到了地震前兆信息。

作者贡献声明: 刘慧,稿件撰写和图件制作;谷洪彪、姚玉霞,论文结构框架设计和监督指导;鲁明贵,稿件审阅与修订。

利益冲突声明: 作者保证本文无任何利益冲突。

参考文献 (References):

- Alghushairy O, Alsini R, Soule T, Ma X G. 2021. A review of local outlier factor algorithms for outlier detection in big data streams. *Big Data and Cognitive Computing*, 5(1): 1
- Audibert J, Michiardi P, Guyard F, Marti S, Zuluaga M A. 2020. USAD: UnSupervised anomaly detection on multivariate time series. In: *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 3395–3404
- Box G E, Jenkins G M, Reinsel G C, Ljung G M. 2015. *Time series analysis: forecasting and control*. John Wiley & Sons.
- Elmaghraby E K, Lotfy Y A. 2009. Differentiation between earthquake radon anomalies and those arising from nuclear activities. *Applied Radiation and Isotopes*, 67(1): 208–211
- Gu Q H, Tian J N, Li X X, Jiang S. 2022. A novel Random Forest integrated model for imbalanced data classification problem. *Knowledge-Based Systems*, 250: 109050
- Guo P, Han Z J, Zhou C, Gai H, Niu P. 2025. Multi - Segment Ruptures of the 2023 Mw 6.0 Jishishan Earthquake, Tibetan Plateau: Implications for Seismogenic Mechanisms of Moderate Earthquakes. *Journal of Geophysical Research: Solid Earth*, 130(4): e2024JB029368–e2024JB029368
- Hartmann J, Levy J K. 2005. Hydrogeological and gasgeochemical earthquake precursors—A review for application. *Natural Hazards*, 34(3): 279–304
- Hashemi S M, Negarestani A, Namvaran M, Musavi Nasab S M. 2013. An analytical algorithm for designing radon monitoring network to predict the location and magnitude of earthquakes. *Journal of Radioanalytical and Nuclear Chemistry*, 295(3): 2249–2262
- Külahcı F, İnceöz M, Doğru M, Aksoy E, Baykara O. 2009. Artificial neural network model for earthquake prediction with radon monitoring. *Applied Radiation and Isotopes*, 67(1): 212–219
- 李营, 陈志, 胡乐, 苏淑娟, 郑辰禾, 刘兆飞, 路畅, 赵影, 刘洁, 何鸿毅, 孙凤霞, 徐超文, 周晓成, 杜建国, 徐胜, 郑国东. 2022. 流体地球化学进展及其在地震预测研究中的应用. *科学通报*, 67(13): 1404–1420 [Li Y, Chen Z, Hu L, Su S J, Zheng C H, Liu Z F, Lu C, Zhao Y, Liu J, He H Y, Sun F X, Xu C W, Zhou X C, Du J G, Xu S, Zheng G D. 2022. Advances in seismic fluid geochemistry and its application in earthquake forecasting. *Chinese Science Bulletin*, 67(13): 1404–1420 (in Chinese with English abstract)]
- 刘春国, 余丹, 陶志刚, 樊俊屹. 2021. 基于数据挖掘的甘肃武都殿沟泉氡异常与地震活动统计关系研究. *地震工程学报*, 43(6): 1263–1268 [Liu C G, Yu D, Tao Z G, Fan J Y. 2021. Statistical relationship between the radon anomaly of Diangou spring and seismic activity in Wudu, Gansu based on data mining technology. *China Earthquake Engineering Journal*, 43(6): 1263–1268 (in Chinese with English abstract)]
- Liu W, Shi Z M, Bai Y F, Yan R, Ma Y C. 2025. Investigating the mechanisms of earthquake - induced groundwater radon changes in a hot spring - insight from coupled flow rates, water temperature, and radon observation. *Journal of Geophysical Research: Solid Earth*, 130(4): e2024JB030878
- 鲁明贵, 谷洪彪, 巩浩波, 张文旭, 迟宝明. 2024. 基于Molchan图表法的流体监测井水位地震预测效能检验. *地震研究*, 47(2): 200–211 [Lu M G, Gu H B, Gong H B, Zhang W X, Chi B M. 2024. Effectiveness test of seismic prediction of water level in fluid monitoring well based on the molchan diagram method. *Journal of Seismological Research*, 47(2): 200–211 (in Chinese with English abstract)]
- Paudel S R, Banjara S P, Wagle A, Freund F T. 2018. Earthquake chemical precursors in groundwater: a review. *Journal of Seismology*, 22(5): 1293–1314
- Singh M, Ramola R C, Singh B, Singh S, Virk H S. 1991. Subsurface soil gas radon changes associated with earthquakes. *International Journal of Radiation Applications and Instrumentation Part D Nuclear Tracks and Radiation Measurements*, 19(1–4): 417–420
- Sreekanth P D, Geethanjali N, Sreedevi P D, Ahmed S, Kumar N R, Kamala Jayanthi P D. 2009. Forecasting groundwater level using artificial neural networks. *Current Science*, 96(7): 933–939
- 孙小龙, 向阳, 杨朋涛. 2018. 云南会泽井水位地震预测效能检验及其机理分析. *地震学报*, 40(2): 185–194 [Sun X L, Xiang Y, Yang P T. 2018. Earthquake prediction efficiency inspection of water level in Huize well and its anomaly mechanism. *Acta Seismologica Sinica*, 40(2): 185–194 (in Chinese with English abstract)]
- 汤大委. 2023. 青藏高原北部和东部强震触发黏弹性数值模拟研究(硕士学位论文). 兰州: 中国地震局兰州地震研究所 [Tang D W. 2023. The numerical simulation study on viscoelastic triggering of strong earthquakes in the northern and eastern Tibetan Plateau (Master Dissertation). Lanzhou: Lanzhou Institute of Seismology (in Chinese with English abstract)]
- Tyralis H, Papacharalampous G, Langousis A. 2019. A brief review of random forests for water scientists and practitioners and their recent history in water resources. *Water*, 11(5): 910
- 王锦红, 蒋海昆. 2023. 基于地震观测数据的机器学习地震预测研究综述. *地震研究*, 46(2): 173–187 [Wang J H, Jiang H K. 2023. Research progress in field of earthquake prediction by machine learning based on seismic data. *Journal of Seismological Research*, 46(2): 173–187 (in Chinese with English abstract)]
- 王宇, 卢文喜, 卞建民, 安永凯. 2015. 基于小波神经网络的地下水流数值模拟模型的替代模型研究. *中国环境科学*, 35(1): 139–146 [Wang Y, Lu

- W X, Bian J M, An Y K. 2015. Surrogate model of numerical simulation model of groundwater based on Wavelet Neural Network. *China Environmental Science*, 35(1): 139–146 (in Chinese with English abstract)]
- Yan X, Shi Z M, Wang G C, Zhang H, Bi E P. 2021. Detection of possible hydrological precursor anomalies using long short-term memory: A case study of the 1996 Lijiang earthquake. *Journal of Hydrology*, 599: 126369
- 杨德贺, 袁静, 王秀英, 申旭辉, 滕海涛, 李文静, 谭巧, 卫清. 2017. 形变观测数据的多异常形态统一识别. *地球物理学报*, 60(12): 4623–4632 [Yang D H, Yuan J, Wang X Y, Shen X H, Teng H T, Li W J, Tan Q, Wei Q. 2017. Identification of multi-anomalies of precursory deformation data. *Chinese Journal of Geophysics*, 60(12): 4623–4632 (in Chinese with English abstract)]
- Yasuoka Y, Ishii T, Tokonami S, Ishikawa T, Narazaki Y, Shinogi M. 2005. Radon anomaly related to the 1995 Kobe earthquake in Japan. *International Congress Series*, 1276: 426–427
- 袁爱璟, 王伟君, 彭菲, 闫坤, 寇华东. 2021. 机器学习在地震预测中的应用进展. *地震*, 41(1): 51–66 [Yuan A J, Wang W J, Peng F, Yan K, Kou H D. 2021. Recent progress of earthquake prediction with machine learning. *Earthquake*, 41(1): 51–66 (in Chinese with English abstract)]
- 曾文浩, 杨兴悦, 史继平, 黄峥峥, 宋婷. 2015. 2013年甘肃岷县漳县MS6.6地震前甘东南地区前兆异常分析. *地震研究*, 38(3): 341–351+517 [Zheng W H, Yang X Y, Shi J P, Huang C C, Song T. 2015. Analysis on the some typical precursory anomalies before Minxian–Zhangxian Ms 6.6 Earthquake in southeast area of Gansu Province in 2013. *Journal of Seismological Research*, 38(3):341–351+517(in Chinese with English abstract)]
- 张慧, 张新基, 苏鹤军. 2005. 强震水氡前兆异常特征及其物理解释. *西北地震学报*, (3):228–232 [Zhang H, Zhang X J, Su H J. 2005. Anomaly characteristics of radon precursory fields in groundwater before strong earthquakes and their physical explanation. *Northwestern Seismological Journal*(3):228–232(in Chinese with English abstract)]
- Zhang S C, Shi Z M, Wang G C, Yan R, Zhang Z C. 2020. Groundwater radon precursor anomalies identification by decision tree method. *Applied Geochemistry*, 121: 104696
- Zhang Y, Tiño P, Leonardis A, Tang K. 2021. A survey on neural network interpretability. *IEEE transactions on emerging topics in computational intelligence*, 5(5): 726–742
- 赵栋, 易立新, 王广才, 张玺. 2013. 地下水位中地震前兆信息提取方法研究. *地震工程学报*, 35(2): 334–341 [Zhao D, Yi L X, Wang G C, Zhang X. 2013. Research on the technology of extracting earthquake precursor information from groundwater level. *China Earthquake Engineering Journal*, 35(2): 334–341 (in Chinese with English abstract)]
- 朱瑞杰. 2023. 基于温泉水化学异常检测算法的地震预测研究(硕士学位论文). 长春: 吉林大学 [Zhu R J. Earthquake prediction based on anomaly detection algorithm of hot spring water chemistry(Master Dissertation). Changchun: Jilin University (in Chinese with English abstract)]

(本文责任编辑: 龚超颖; 英文审校: 张兴春)